

CUDSS Raport 05.06.2026

Konfiguracja środowisk testowych pozostała niezmienną względem poprzedniego etapu prac. Testy nadal realizowano zarówno w środowisku lokalnym, jak i w środowisku chmurowym RunPod.io, co umożliwiło porównanie zachowania biblioteki cuDSS dla problemów o różnej skali oraz na różnych konfiguracjach sprzętowych.

W bieżącym etapie skupiono się przede wszystkim na rozszerzeniu zakresu testów wydajnościowych, weryfikacji poprawności uzyskiwanych rozwiązań oraz analizie stabilności wyników poprzez wykonywanie serii wielokrotnych uruchomień dla tych samych przypadków testowych. Szczególną uwagę poświęcono pomiarom dla większych macierzy uruchamianych w środowisku chmurowym, które ze względu na wymagania pamięciowe nie mogły być efektywnie analizowane na sprzęcie lokalnym.

Specyfikacja wykorzystywanych środowisk obliczeniowych została przedstawiona w poprzednim raporcie i pozostaje aktualna również dla niniejszego etapu prac.

Szczegółowe wyniki pomiarów wykorzystanych w niniejszej analizie zostały dołączone do raportu w postaci odpowiednio opisanych plików tekstowych. W dalszej części dokumentu odwołania dotyczą przede wszystkim plików:

- cudss_ldlt_472096_original_rhs_10runs_local.txt,
- ldlt_1432119_original_rhs_10runs_cloud.txt.

W odpowiedzi na uwagę dotyczącą sposobu wykonywania pomiarów wydajnościowych rozszerzono metodologię badań o wielokrotne uruchomienia dla każdego analizowanego przypadku. Dla każdej konfiguracji wykonano serię 10 kolejnych pomiarów, a następnie wyznaczono średnie, minimalne oraz maksymalne czasy realizacji poszczególnych faz obliczeń.

Pomiary przeprowadzono zarówno w środowisku lokalnym, jak i w środowisku chmurowym. W środowisku lokalnym wykorzystano macierz o rozmiarze 472 096 niewiadomych i 9 032 284 elementach niezerowych, natomiast w środowisku chmurowym wykonano testy dla macierzy o rozmiarze 1 432 119 niewiadomych i 54 237 734 elementach niezerowych.

Uzyskane wyniki wykazały wysoką powtarzalność pomiarów. Dla środowiska lokalnego średni czas fazy faktoryzacji wyniósł 1935,7 ms, przy minimalnej wartości 1920,4 ms i maksymalnej 1945,8 ms. Średni czas fazy rozwiązywania układu wyniósł 31,5 ms, a

wartości minimalna i maksymalna odpowiednio 30,2 ms oraz 39,2 ms. Otrzymane wyniki wskazują na niewielki rozrzut pomiędzy kolejnymi uruchomieniami.

Analogiczną procedurę zastosowano w środowisku chmurowym. Dla większego problemu średni czas faktoryzacji wyniósł 2153,4 ms (minimum 2149,4 ms, maksimum 2169,1 ms), natomiast średni czas fazy Solve wyniósł 49,4 ms (minimum 47,7 ms, maksimum 63,9 ms). Również w tym przypadku zaobserwowano bardzo dobrą powtarzalność wyników pomiędzy kolejnymi uruchomieniami.

Dodatkowo dla wszystkich testów zweryfikowano poprawność uzyskanych rozwiązań poprzez obliczenie błędu rezydualnego. Zarówno dla środowiska lokalnego, jak i chmurowego uzyskano wartości rzędu 10^{-11} – 10^{-12} , co potwierdza poprawność numeryczną obliczeń.

Wprowadzenie serii wielokrotnych uruchomień pozwoliło uzyskać bardziej reprezentatywne wyniki wydajnościowe oraz ograniczyć wpływ pojedynczych odchyłeń wynikających z działania systemu operacyjnego, sterowników GPU lub mechanizmów zarządzania pamięcią urządzenia.

Szczegółowe wyniki testów przeprowadzonych dla różnych wektorów prawych stron zostały dołączone do raportu w postaci odpowiednio opisanych plików tekstowych. W dalszej części dokumentu odwołania dotyczą przede wszystkim plików:

- cudss_ldlt_472096_original_rhs_5runs_local.txt,
- cudss_ldlt_472096_dense_rhs_5runs_local.txt,
- cudss_ldlt_472096_random_rhs_5runs_local.txt,
- ldlt_1432119_original_rhs_5runs_cloud.txt,
- ldlt_1432119_dense_rhs_5runs_cloud.txt,
- ldlt_1432119_random_rhs_5runs_cloud.txt.

W odpowiedzi na uwagę dotyczącą wpływu struktury wektora prawej strony na wydajność obliczeń przeprowadzono dodatkowe testy dla trzech różnych typów wektorów b:

- oryginalnego wektora dostarczonego wraz z macierzą testową,
- pełnego wektora zawierającego same jedynki,
- wektora losowego.

Badania wykonano zarówno dla mniejszego problemu uruchamianego w środowisku lokalnym, jak i dla większego problemu analizowanego w środowisku chmurowym.

Dla macierzy o rozmiarze 472 096 niewiadomych średni czas fazy Solve wyniósł odpowiednio 32,2 ms dla oryginalnego wektora, 32,5 ms dla wektora pełnego oraz 32,8 ms dla wektora losowego. Średni czas faktoryzacji mieścił się w przedziale od 1935,8 ms do 1945,4 ms. Różnice pomiędzy poszczególnymi wariantami były niewielkie i nie przekraczały około 1% wartości średnich.

Analogiczne obserwacje poczyniono dla większej macierzy o rozmiarze 1 432 119 niewiadomych. Średni czas fazy Solve wyniósł odpowiednio 51,0 ms dla oryginalnego wektora, 51,1 ms dla wektora pełnego oraz 51,0 ms dla wektora losowego. Średni czas faktoryzacji zawierał się w zakresie od 2154,2 ms do 2155,1 ms. Także w tym przypadku nie zaobserwowano istotnych różnic pomiędzy badanymi wariantami.

Na podstawie przeprowadzonych eksperymentów nie stwierdzono istotnego wpływu struktury elementów niezerowych wektora b na wydajność biblioteki cuDSS dla analizowanych przypadków testowych. Otrzymane wyniki sugerują, że dominujący wpływ na czas obliczeń mają właściwości analizowanej macierzy oraz proces faktoryzacji, natomiast zmiana struktury pojedynczego wektora prawej strony nie powoduje zauważalnych zmian wydajności.

W odpowiedzi na uwagę dotyczącą monitorowania liczby elementów niezerowych faktorów przeanalizowano możliwości biblioteki cuDSS w tym zakresie. Biblioteka cuDSS nie udostępnia jednak w obecnej wersji API bezpośredniej informacji o liczbie elementów niezerowych faktorów powstałych podczas faktoryzacji, co uniemożliwia wyznaczenie proponowanego współczynnika odnoszącego liczbę elementów niezerowych faktorów do liczby elementów niezerowych macierzy wejściowej.

W związku z tym jako pośrednią miarę zastosowano monitorowanie wykorzystania pamięci GPU. Rozmiar faktorów oszacowano jako przyrost zajętości pamięci pomiędzy etapami Analysis i Factorization. Pozwala to pośrednio ocenić koszt przechowywania faktorów oraz porównywać różne warianty faktoryzacji (LU oraz LDL^T), jednak bez możliwości bezpośredniego wyznaczenia liczby elementów niezerowych generowanych przez bibliotekę.

W odpowiedzi na uwagę dotyczącą krótkich czasów fazy Solve dla faktoryzacji LDLT przeprowadzono dodatkową weryfikację metodologii pomiarów. Program został rozszerzony o synchronizację GPU przed zakończeniem pomiaru czasu każdej fazy obliczeń, co gwarantuje uwzględnienie rzeczywistego czasu wykonania operacji na urządzeniu.

Dodatkowo wykonano serie wielokrotnych uruchomień dla analizowanych przypadków testowych oraz przeprowadzono obliczenia dla różnych wektorów prawych stron (oryginalnego, pełnego oraz losowego). Uzyskane wyniki potwierdziły wysoką powtarzalność pomiarów oraz brak istotnego wpływu struktury pojedynczego wektora b na czasy wykonania. Na podstawie przeprowadzonych eksperymentów nie stwierdzono przesłanek wskazujących na błędny pomiar czasu fazy Solve dla biblioteki cuDSS.